UNIVERSIDADE REGIONAL DE BLUMENAU

CENTRO DE CIÊNCIAS EXATAS E NATURAIS

CURSO DE CIÊNCIA DA COMPUTAÇÃO

Processamento de Linguagem Natural

2026/2

Trabalho da Unidade 3

Equipe: Alana Cristina Andreazza, Beatriz Moresco Joaquim, Caio Abraão, Haiko Rudiger e Letícia Fruet.

Empregando os dados textuais obtidos por cada grupo, avaliem os resultados obtidos da combinação de diferentes representações textuais e técnicas/tarefas de Processamento de Linguagem Natural.

1) Iniciem marcando a lista abaixo com ✔ para as atividades efetivamente realizadas. Se não foram realizadas, incluam uma breve justificativa (ver exemplo abaixo).

	BoW	TF-IDF	Word2Vec	BERT
Clusterização + PCA e visualização	✔	✔	✔	✔
Busca e recomendação	✔	✔	✔	✔
Classificação	✔	✔	✔	✔

Análise de sentimento	( ) Foi realizada	(X) Não foi realizada
Reconhecimento de Entidades Nomeadas	(X) Foi realizado	( ) Não foi realizado
Extração de Relações	(X) Foi realizado	( ) Não foi realizado

A análise de sentimentos não foi executada, pois o conjunto de dados possui avaliações numéricas, mas não contém comentários textuais necessários à análise de opiniões.

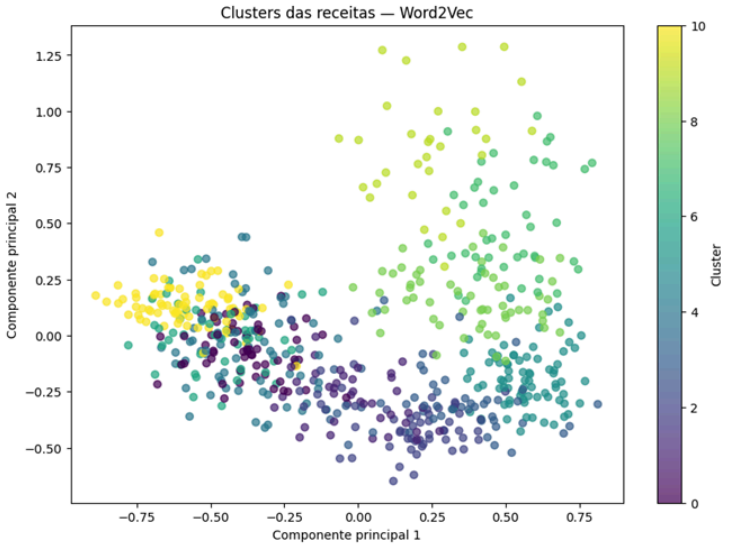
2) Avaliem qualitativamente, a partir dos resultados e da leitura dos textos, qual representação gerou clusters mais representativos para os dados. Qual a quantidade de clusters que melhor expressou as características originais dos dados?

Insiram imagens e interpretem as métricas intra e interclusters.

As 620 receitas foram agrupadas pelo algoritmo K-Means, utilizando BoW, TF-IDF, Word2Vec e BERTimbau, com 11 clusters correspondentes à quantidade de categorias originais.

Representação	**Silhouette Score**
Word2Vec	0,101
BERTimbau	0,062
BoW	0,056
TF-IDF	0,036

O Word2Vec apresentou o melhor resultado (0,101), indicando maior coesão interna e separação relativa entre os clusters. Entretanto, os baixos valores de Silhouette evidenciam sobreposição entre os agrupamentos, também observada na visualização por PCA. Embora tenham sido utilizados 11 clusters, não é possível afirmar que essa seja a quantidade ideal, pois outros valores não foram testados.



3) Apresentem resultados de busca e analisem criticamente a qualidade dos top-3 e top-5 documentos retornados para cada representação. Os resultados são utilizáveis em um contexto real? Como poderiam ser combinados ou melhorados?

Foram realizadas três consultas (“bolo fubá”, “frango com batata” e “risoto de carne”), comparando os resultados Top-3 e Top-5 das quatro representações. BoW e TF-IDF apresentaram os resultados mais relevantes, especialmente nas duas primeiras consultas. Para “bolo fubá”, ambos recuperaram receitas correspondentes nas três primeiras posições, enquanto o Word2Vec também apresentou resultados relacionados, incluindo “Bolo de laranja” na quinta posição. O BERTimbau apresentou menor pertinência, retornando principalmente bebidas e receitas não relacionadas à consulta.

Na busca por “frango com batata”, BoW e TF-IDF recuperaram a receita de mesmo nome na segunda posição, enquanto o Word2Vec a encontrou na quarta. Já na consulta “risoto de carne”, os métodos demonstraram maiores dificuldades: os resultados Top-3 priorizaram receitas de carne ou pratos pouco relacionados, e apenas o Word2Vec recuperou uma receita contendo risoto no Top-5.

A avaliação de similaridade entre receitas também considerou a coerência média do Top-5, calculada pela proporção de receitas recuperadas que compartilham ao menos uma categoria com a receita de referência:

Representação	**Coerência Top-5**
TF-IDF	0,607
Word2Vec	0,563
BoW	0,550
BERTimbau	0,441

O TF-IDF apresentou o melhor desempenho nessa métrica, embora ela não avalie diretamente a relevância das consultas textuais. Os resultados indicam potencial para utilização em um sistema real, mas ainda apresentam limitações, principalmente em buscas mais específicas. Para melhorar a relevância, recomenda-se combinar TF-IDF e Word2Vec, além de implementar filtros por ingredientes e categorias.

4) Foi possível treinar um classificador? Como ele se comportou a partir de dados novos?

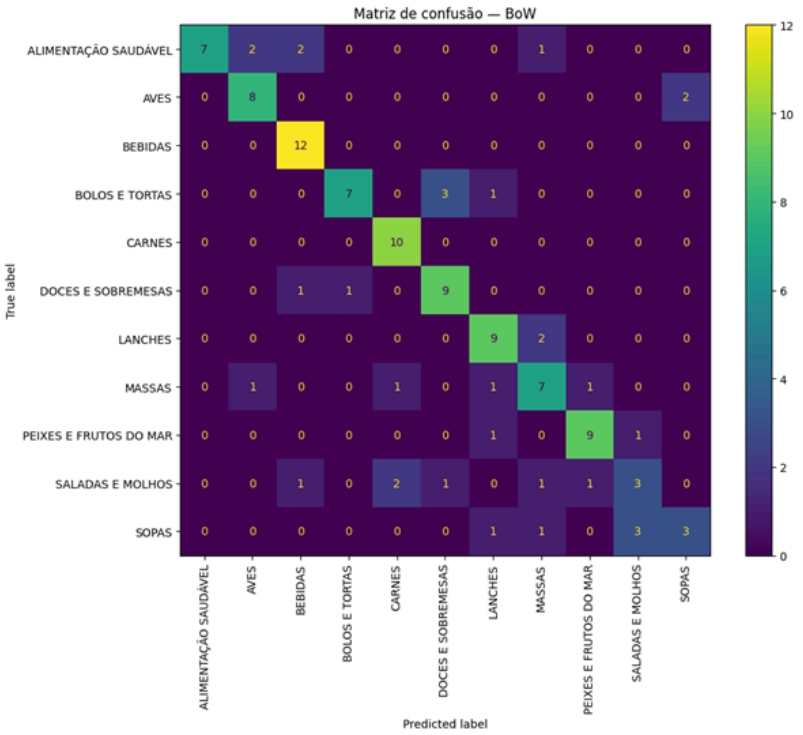
Alguma representação textual favorece classificações mais precisas? Quais? Foi utilizada alguma técnica utilizando modelos de linguagem ou de modelos de decisão? Explique.

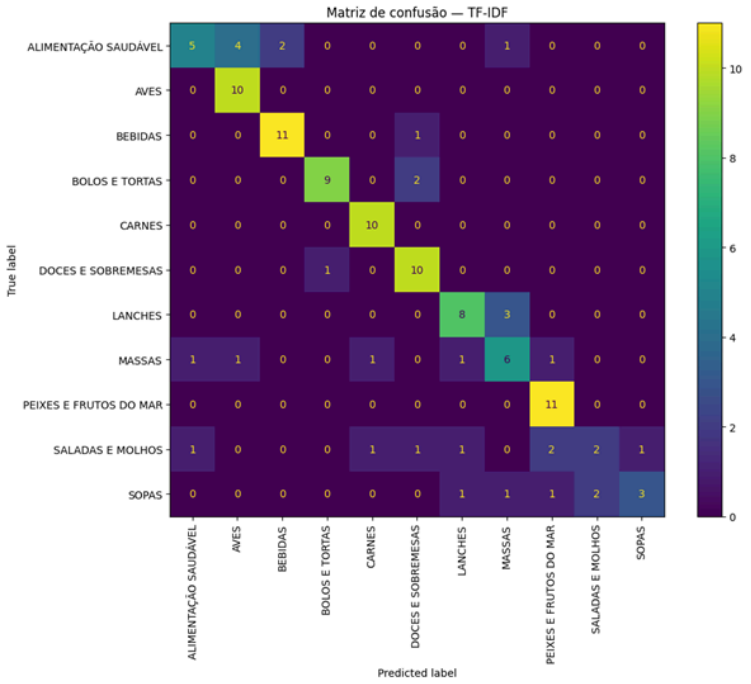
Foram treinados classificadores com Regressão Logística utilizando BoW, TF-IDF, Word2Vec e BERTimbau. Das 620 receitas iniciais, 40 foram excluídas por pertencerem a múltiplas categorias, restando 580 receitas, divididas em 80% para treinamento e 20% para teste.

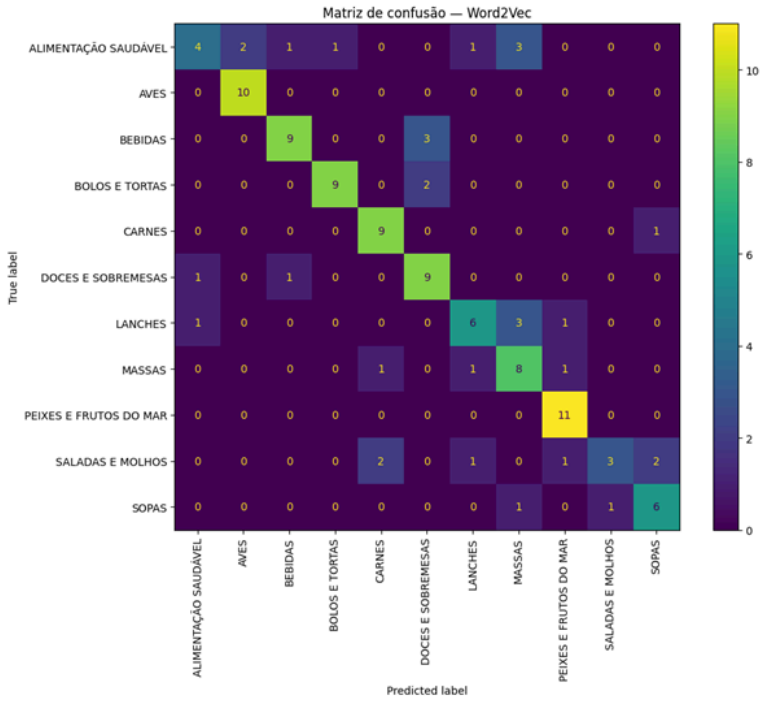
Representação	**Acurácia**	**Precisão macro**	**Revocação macro**	**Macro F1**
TF-IDF	0,733	0,721	0,721	0,700
Word2Vec	0,724	0,728	0,725	0,709
BoW	0,724	0,721	0,711	0,702
BERTimbau	0,664	0,652	0,647	0,630

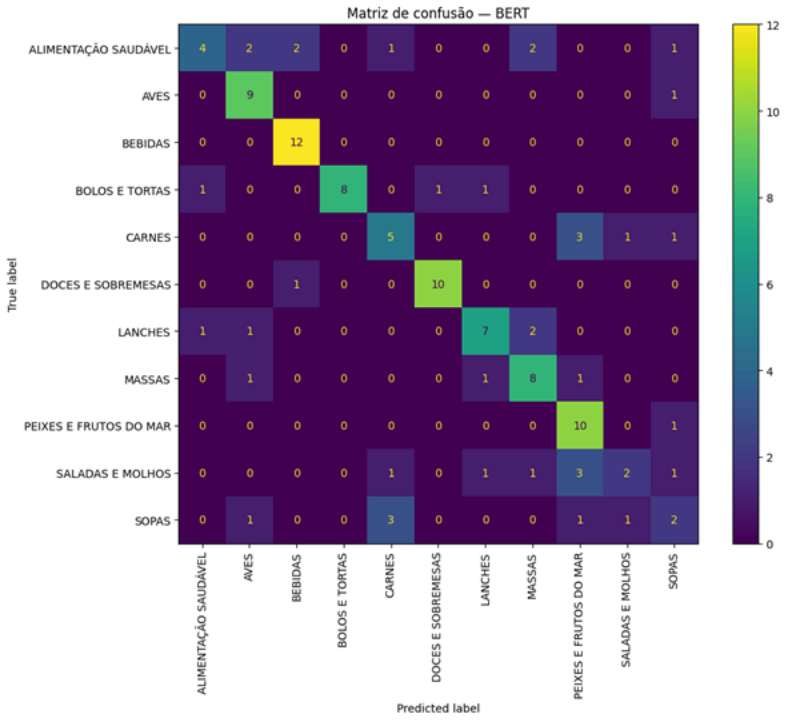
O TF-IDF apresentou a maior acurácia (73,3%), enquanto o Word2Vec obteve o melhor Macro F1 (0,709), demonstrando melhor equilíbrio entre as categorias. As matrizes de confusão evidenciaram bons resultados em AVES, CARNES e PEIXES E FRUTOS DO

MAR, mas maiores dificuldades em SALADAS E MOLHOS, SOPAS e ALIMENTAÇÃO SAUDÁVEL. O BERTimbau foi utilizado para gerar embeddings, sem ajuste fino do modelo.









Nos testes com quatro receitas novas, TF-IDF e Word2Vec acertaram todos os exemplos (4/4), enquanto BERTimbau acertou três (3/4) e BoW apenas um (1/4). Entretanto, essa amostra é insuficiente para avaliar a generalização dos modelos, sendo mais representativos os resultados das 116 receitas de teste. O BERTimbau foi utilizado para gerar embeddings, sem ajuste fino (fine-tuning), seguido de Regressão Logística.

5) Análise de sentimentos, Extração de Entidades Nomeadas e Extração de Relações são aplicáveis aos dados coletados? Em caso positivo, que tipo de resultado foi obtido?

A análise de sentimentos não foi realizada, pois a base contém avaliações numéricas, mas não possui comentários textuais. O NER, utilizando o modelo spaCy pt_core_news_sm, identificou 90 menções a entidades em uma amostra de 55 receitas, incluindo classificações incorretas, como “Bolo” identificado como pessoa e “Carne” como local.

A extração de relações analisou 160 etapas de preparo e identificou 182 relações sintáticas candidatas em 51 receitas, principalmente entre verbos e seus complementos. Os resultados demonstram a aplicabilidade das técnicas, mas evidenciam a necessidade de adaptar os modelos ao vocabulário culinário e validar as informações extraídas.

6) As técnicas estudadas auxiliam na concretização do projeto apresentado na Unidade 1? Expliquem.

As técnicas de PLN contribuem para o projeto de organização, classificação e recomendação de receitas. BoW e TF-IDF facilitam a busca, enquanto Word2Vec permite identificar receitas semelhantes. A clusterização auxilia no agrupamento, embora os baixos valores de Silhouette indiquem limitações.

A classificação supervisionada apresentou resultados satisfatórios, com acurácia de até 73,3%. O NER e a extração de relações possibilitam identificar informações nas instruções culinárias, mas necessitam de aprimoramentos. Assim, a combinação de TF-IDF, Word2Vec e Regressão Logística demonstra potencial para o desenvolvimento do projeto.

Instruções gerais:

- ➔ O código e os resultados devem ser inseridos em pasta específica do repositório indicado em trabalhos anteriores.
- ➔ As respostas 2, até 6, acima, deverão ser apresentadas em formato de texto descritivo/argumentativo, sempre que possível amparados por figuras, exemplos dos dados, resultados e trechos de código.
- ➔ Para testes de implementação das técnicas, é permitido o uso de amostragens menores dos dados obtidos, desde que explicitado.
- ➔ É permitido o uso auxiliar de IA generativa, desde que indicado explicitamente o fornecedor/modelo e prompts utilizados.

O prompt utilizado para gerar a implementação da etapa de classificação foi anexado ao repositório no GitHub com o nome **prompt_classificação.txt**.